

NGHIÊN CỨU ỨNG DỤNG ACTIVE LEARNING ĐỂ GIẢM CHI PHÍ GÁN NHÃN DỮ LIỆU

BÀI TOÁN NHẬN DẠNG THỰC THỂ CÓ TÊN (BioNER) CHO VĂN BẢN Y SINH HỌC
TIẾNG VIỆT

Báo cáo Môn học: Xử lý Ngôn ngữ Tự nhiên

Sinh viên thực hiện: Nguyễn Hà Phương Uyên - 65KTPM

Giảng viên hướng dẫn: PGS.TS Nguyễn Quang Hoan

MỤC LỤC TỔNG QUAN

- 1 Thực trạng & Thách thức:** Sự bùng nổ dữ liệu y khoa, chi phí gán nhãn, và vấn đề mất cân bằng thực thể nghiêm trọng.
- 2 Giải pháp đề xuất:** Quy trình tích hợp Học chủ động (AL) và Thế thực thể (DES), sơ đồ kiến trúc và pipeline.
- 3 Thực nghiệm & Kết quả:** Thiết lập đối chứng, tiến trình F1-score, phân tích AULC, và kiểm định thống kê.
- 4 Kết luận & Phát triển:** Tổng kết đóng góp, đánh giá hạn chế thực tiễn và định hướng tương lai.



1. THỰC TRẠNG & NHU CẦU TỰ ĐỘNG HÓA

Thực trạng dữ liệu Y tế



Hồ sơ bệnh án, bệnh lịch lâm sàng tại Việt Nam được số hóa nhanh chóng nhưng chủ yếu ở dạng **văn bản phi cấu trúc** (Free-text).

Khai thác thông tin thủ công gây quá tải nghiêm trọng cho đội ngũ y tế, làm mất nhiều thời gian và dễ dẫn đến sai sót, bỏ sót chỉ định.

Nhu cầu Tự động hóa (BioNER)



Cần hệ thống **Nhận dạng thực thể y sinh (BioNER)** tự động trích xuất: Triệu chứng, bệnh lý, quy trình chẩn đoán, ngày tháng...

Chuyển đổi văn bản tự do thành các biểu diễn cấu trúc, tạo nền tảng phục vụ các Hệ thống Hỗ trợ Ra quyết định Lâm sàng (CDSS).

THÁCH THỨC CỦA CÁC GIẢI PHÁP HIỆN NAY



Chi phí & Dữ liệu

Các mô hình học sâu SOTA đòi hỏi **hàng ngàn câu huấn luyện**. Gán nhãn y khoa bắt buộc do bác sĩ thực hiện khiến chi phí cực kỳ đắt đỏ.



Mất cân bằng nhãn

Sự chênh lệch lớn: Các thực thể hiếm (như quy trình chẩn đoán, tổ chức y tế) xuất hiện rất ít, khiến mô hình dễ bỏ sót (Recall thấp).



Giải pháp định hướng

Tích hợp **Active Learning (AL)** để chọn mẫu thông minh và **Dictionary-based Entity Substitution (DES)** để tăng cường nhãn hiếm.

2. GIẢI PHÁP ĐỀ XUẤT & MỤC TIÊU

Câu hỏi nghiên cứu

Liệu chiến lược chọn mẫu thông minh (độ bất định + đa dạng) có giúp đạt F1-score cao hơn với ít câu gán nhãn hơn so với lấy mẫu ngẫu nhiên (Random Sampling)?

Giải pháp tích hợp

Active Learning (AL): Dựa trên độ bất định CRF Marginal Entropy và bộ lọc Distinct-K Filter để chọn mẫu tối ưu nhất cho mỗi vòng.

Entity Substitution (DES): Tăng cường dữ liệu bằng thể thực thể thích ứng theo lớp từ từ điển, giải quyết triệt để mất cân bằng lớp.

THU THẬP DỮ LIỆU & PHÂN BỐ THỰC THỂ

Nguồn dữ liệu: Bộ dữ liệu **VietBioNER** (Phan et al., 2022) về bệnh lao phổi từ hồ sơ lâm sàng.
Đặc tính: 1.362 câu sạch (42.516 tokens). Thể hiện sự mất cân bằng lớp nghiêm trọng giữa các thực thể.

Loại thực thể (Entity Type)	Train	Validation	Test	Tổng cộng	Tỷ lệ (%)
Symptom_and_Disease (Triệu chứng/Bệnh)	1.541	179	181	1.901	59.42%
DiagnosticProcedure (Quy trình chẩn đoán)	356	63	38	457	14.29%
Location (Vị trí/Địa điểm)	283	36	45	364	11.38%
DateTime (Thời gian)	231	26	23	280	8.75%
Organisation (Tổ chức Y tế)	154	16	27	197	6.16%

QUY TRÌNH PIPELINE THỰC NGHIỆM

GIAI ĐOẠN II Huấn luyện & Tăng cường

Tăng cường tập L_t bằng DES. Định dạng ghép nối ETD, Negative Sampling. Huấn luyện mô hình LoRA-CRF. Đánh giá trên tập Test.

GIAI ĐOẠN IV Cập nhật & So sánh

Cập nhật lại tập gán nhãn L_{t+1} và tập chưa gán nhãn U_{t+1} . Lặp lại quá trình. So sánh nhánh AL với nhánh Random Sampling.

GIAI ĐOẠN I Khởi tạo chung

Tiền xử lý, tách từ ghép (PyVi), đồng bộ nhãn BIO. Phân chia Train/Val/Test. Lấy mẫu phân tầng tạo Seed Set L_0 (85 câu).


GIAI ĐOẠN III Chọn dữ liệu gán nhãn

Đối với nhánh Active Learning: Suy luận trên tập U_t , chọn 100 câu khó nhất bằng Entropy + Distinct-K Filter.

Đối với nhánh Random: Chọn 100 câu ngẫu nhiên.

Pre-annotation và Oracle Feedback (chuyên gia sửa nhãn).

KIẾN TRÚC MÔ HÌNH ĐỀ XUẤT (LoRA-CRF)



Encoder Backbone: ViPubmedDeBERTa-base

Sử dụng mô hình ngôn ngữ y sinh tiếng Việt (86M tham số). *Đóng băng toàn bộ trọng số gốc để tiết kiệm tính toán.*



Low-Rank Adaptation (LoRA)

Gắn LoRA (Rank $r=16$, Alpha=32) vào ma trận chiếu Query và Value. *Chỉ cập nhật 1.8% tham số, ngăn ngừa hiện tượng quá khớp (overfitting) trên tập dữ liệu AL nhỏ hẹp.*



Đầu phân loại (Linear + CRF Head)

Loại bỏ BiLSTM truyền thống để tránh loãng ngữ cảnh. Sử dụng CRF với trọng số loss thích ứng theo lớp (Class-weighted CRF Loss) để ưu tiên dự đoán các thực thể hiếm.



Động học che giấu ngữ cảnh (Contextual Masking)

Che giấu ngẫu nhiên 18% thực thể và 15% từ ngữ cảnh (kích hoạt từ vòng 2) nhằm chống lại hiện tượng mô hình "học vẹt" ngữ cảnh cố định sinh ra từ thuật toán DES.

CHIẾN LƯỢC CHỌN MẪU HỌC CHỦ ĐỘNG (AL)

1. CRF Marginal Entropy (Độ bất định): Đo lường độ không chắc chắn của mô hình đối với câu chưa gán nhãn dựa trên xác suất biên của lớp CRF. Chỉ tính trên các token thuộc về câu gốc S (loại trừ các token định dạng).

$$\text{Uncertainty} (S) = - \frac{1}{|S|} \sum_{i \in \text{seq_ids}} \sum_l P (y_i = l | X) \log P (y_i = l | X)$$

2. Distinct-K Filter (Độ đa dạng): Sắp xếp theo độ bất định giảm dần. Nhúng vector câu bằng Sentence-BERT. Chỉ chọn câu vào batch nếu Cosine Similarity với các câu đã chọn trong batch < 0.85 (tránh chọn các mẫu trùng lặp về ngữ nghĩa).

TĂNG CƯỜNG THỂ THỰC THỂ DỰA TRÊN TỪ ĐIỂN



Zero-Leakage Filter (Không rò rỉ): Đối chiếu loại bỏ toàn bộ thuật ngữ xuất hiện trong tập Val/Test ra khỏi từ điển Gazetteer, đảm bảo đánh giá khách quan.

- symptom_and_disease.json: Loại bỏ 18 từ khóa (còn lại 161 từ khóa).
- diagnostic_procedures_tb.json: Loại bỏ 1 từ khóa (còn lại 326 từ khóa).
- location.json: Loại bỏ 5 từ khóa (còn lại 175 từ khóa).
- datetime.json: Loại bỏ 1 từ khóa (còn lại 161 từ khóa).
- healthcare_organizations.json: Loại bỏ 2 từ khóa (còn lại 552 từ khóa).



Thể thích ứng theo lớp: Xác suất thể và số bản sao phụ thuộc vào độ hiếm. Ví dụ: SYM thể 50% (1 bản sao), ORG thể 100% (3 bản sao) để làm giàu từ vựng nhóm yếu.



Thuật toán BIO Label Shift: Khi thay thế thực thể cũ bằng thực thể mới có số token khác biệt, tự động dịch chuyển chỉ mục nhãn BIO của phần còn lại để bảo toàn tính toàn vẹn.

3. THIẾT LẬP THỰC NGHIỆM ĐỐI CHỨNG

Xuất phát từ cùng tập hạt giống (Seed Set) gồm 85 câu. Chạy qua 5 vòng huấn luyện lặp, ngân sách thêm 100 câu mỗi vòng (tối đa đạt 485 câu - chiếm ~45% Train gốc).

Nhánh A (Đề xuất): AL + DES

Chọn batch 100 câu thông minh bằng CRF Marginal Entropy và Distinct-K Filter.



Nhánh B (Baseline): Random + DES

Chọn ngẫu nhiên (Random Sampling) batch 100 câu từ tập chưa gán nhãn.

KẾT QUẢ: TIẾN TRÌNH HIỆU NĂNG QUA CÁC VÒNG

Nhánh thí nghiệm	Vòng lặp	Số câu gán nhãn ()	Chi phí sửa vòng này	Chi phí sửa lũy kế ()	Precision (%)	Recall (%)	F1-score (%)
Nhánh A+B (khởi tạo đồng bộ)	Vòng 0	85	919	919	46.62%	43.23%	44.86%
Nhánh A (AL)	Vòng 1	185	638	1.557	58.47%	58.09%	58.28%
	Vòng 2	285	423	1.980	67.89%	67.00%	67.44%
	Vòng 3	385	282	2.262	65.03%	61.39%	63.16%
	Vòng 4 (Cuối)	485	294	2.556	72.09%	71.62%	71.85%
Nhánh B (Random)	Vòng 1	185	336	1.255	54.77%	58.75%	56.69%
	Vòng 2	285	242	1.497	54.09%	61.06%	57.36%
	Vòng 3	385	224	1.721	66.15%	70.30%	68.16%
	Vòng 4 (Cuối)	485	246	1.967	60.67%	65.68%	63.07%

ĐƯỜNG CONG HỌC TẬP & DIỆN TÍCH TÍCH LŨY



AULC (Area Under Learning Curve):

Nhánh AL: 24.723,66 F1-câu.

Nhánh Random: 23.618,10 F1-câu.

Mức cải thiện: +1.105,56 F1-câu (+4.68% năng lực)

ĐƯỜNG CONG HỌC TẬP & ĐIỆN TÍCH TÍCH LŨY

Mốc F1 mục tiêu (%)	Quy mô N_t (AL)	Quy mô N_t (Random)	SSR (%)	Chi phí E_t (AL)	Chi phí E_t (Random)	ESR (%)
60.00%	203,8 câu	309,4 câu	34.14%	1.636,5	1.551,7	-5.46%
63.07% (F1 Rand vòng cuối)	237,3 câu	337,9 câu	29.76%	1.778,2	1.615,4	-10.08%
65.00%	258,4 câu	355,7 câu	27.37%	1.867,3	1.655,4	-12.80%
70.00%	463,7 câu	385,0 câu*	-20.44%*	2.493,3	1.721,0*	-44.88%*

- Tỷ lệ tiết kiệm mẫu câu (SSR): Tại mốc F1 60.0%, SSR đạt **34.14%** (Tiết kiệm ~1/3 khối lượng đọc cho bác sĩ).
- Tỷ lệ tiết kiệm sửa nhãn (ESR): Mang giá trị âm (~ -10%). Ý nghĩa: AL chọn mẫu khó, cấu trúc phức tạp nên bắt buộc chuyên gia sửa nhiều thao tác hơn trên từng câu được chọn.

ĐÁNH GIÁ CHI TIẾT THEO LỚP THỰC THỂ (VÒNG 4)

Hiệu năng F1-score chi tiết tại ngân sách 485 câu. Nhánh AL đạt cải thiện vượt trội đồng đều ở tất cả 5 phân lớp.

Loại Thực thể	Nhánh A (AL)	Nhánh B (Random)	Chênh lệch	Support (Test)
Symptom_and_Disease	76.55%	68.29%	+8.26%	184
DiagnosticProcedure	49.28%	40.96%	+8.31%	37
Location	67.53%	57.50%	+10.03%	37
DateTime	80.85%	77.55%	+3.30%	23
Organisation	65.00%	56.00%	+9.00%	22

Đặc biệt giải quyết lỗi ranh giới phức tạp ở lớp khó DiagnosticProcedure và Organisation.

SO SÁNH ĐỐI CHIẾU VỚI NGHIÊN CỨU GỐC

So sánh trên tập Test của VietBioNER (Lao phổi):

Nghiên cứu / Kiến trúc	Cỡ mẫu huấn luyện	F1-score (%)
LREC 2022: Bi-LSTM Baseline	706 câu (100% Train gốc)	78.42%
LREC 2022: PhoBERT-base (SOTA)	706 câu (100% Train gốc)	79.60%
Đề tài: Nhánh Baseline (Random)	485 câu (~45% Train mới)	63.07%
Đề tài: Nhánh Đề xuất (AL + DES)	485 câu (~45% Train mới)	71.85%

Nhận xét: Mô hình đạt 71.85% F1, chỉ kém SOTA PhoBERT 7.75% nhưng **tiết kiệm được 55% khối lượng dữ liệu cần gán nhãn**. Giải quyết triệt để điểm nghẽn hiệu năng ở lớp DiagnosticProcedure của nghiên cứu gốc.

4. KẾT LUẬN & ĐÓNG GÓP CHÍNH



Hoàn thành Mục tiêu

Đạt hiệu năng F1-score **71.85%** dưới ngân sách cực kỳ giới hạn 485 câu. Tỷ lệ tiết kiệm câu (SSR) đạt **34.14%**, xác nhận tính hiệu quả thực tiễn cao.



Phương pháp luận

Thiết lập thành công quy trình lập tích hợp tối ưu giữa **Học chủ động AL** và **Tăng cường DES (Zero-Leakage)**, giải quyết đồng thời bài toán chi phí và mất cân bằng nhãn.




Kiến trúc Hệ thống

Xây dựng thành công hệ thống **ViPubmedDeBERTa + LoRA + CRF** kết hợp cơ chế lấy mẫu âm tính (Negative Sampling) đem lại hiệu quả tinh chỉnh cực tốt trên dữ liệu y sinh nhỏ.

HẠN CHẾ CỦA NGHIÊN CỨU HIỆN TẠI

-  **Hạn chế hạt giống ngẫu nhiên:** Do giới hạn GPU (Colab miễn phí), quy trình AL chỉ mới báo cáo trên duy nhất 1 hạt giống ngẫu nhiên (SEED = 42).
-  **Nhiều cú pháp từ Gazetteer:** Chèn ngẫu nhiên từ khóa gây mất liên kết cú pháp tự nhiên
-  **Chưa tối ưu hóa:** Chưa thực hiện Grid Search cho LoRA.



Hướng phát triển tương lai

DES có nhận thức ngữ pháp: Phát triển cơ chế thể thực thể dựa trên sự tương đồng POS (Part-of-Speech) để đảm bảo từ khóa thay thế luôn phù hợp với cấu trúc cú pháp của câu văn gốc.

Mở rộng quy mô thực nghiệm: Khảo sát trên nhiều hạt giống ngẫu nhiên (seeds) để tính khoảng tin cậy và nâng cao ý nghĩa thống kê của phép thử.

Tự động tối ưu siêu tham số: Áp dụng Grid Search hoặc tối ưu Bayes cho LoRA adapters.

Interactive Annotation Tool: Phát triển giao diện gán nhãn tương tác chạy trên Web tích hợp AL + DES để hỗ trợ bác sĩ lâm sàng hiệu chỉnh nhãn trong thời gian thực.

**CẢM ƠN THẦY CÔ ĐÃ LẮNG
NGHE!**